

Segmentação de Instância de Animais de Estimação com YOLOv8: um Estudo de Caso no Dataset Oxford-IIIT Pet

Katelyn Moura, Diego Rodrigues, Idelmar Júnior,
Renan Costa, Thiago Novaes

¹Curso Técnico/Superior em Informática – Instituto Federal do Piauí (IFPI)
Campus Picos – Picos, PI – Brasil

{katelyn.moura, diego.rodrigues, idelmar.junior, renan.costa, thiago.novaes}@aluno.ifpi.edu.br

Resumo. A segmentação é uma das tarefas fundamentais da visão computacional, permitindo a classificação de imagens no nível de pixel. Este trabalho apresenta a aplicação da arquitetura YOLOv8-seg para a tarefa de segmentação de instância de animais de estimação (cães e gatos), utilizando o dataset público Oxford-IIIT Pet. Como o dataset original disponibiliza apenas máscaras densas (trimaps), foi desenvolvido um pipeline de conversão para o formato de polígonos exigido pela arquitetura. O modelo foi treinado por transfer learning a partir de pesos pré-treinados no COCO, e avaliado por métricas de mean Average Precision (mAP) de máscara. Os resultados demonstram [preencher após o treinamento], evidenciando a viabilidade do uso de arquiteturas de detecção com cabeça de segmentação para problemas de granularidade fina com poucos recursos computacionais.

Abstract. Segmentation is one of the fundamental tasks in computer vision, enabling pixel-level image classification. This work presents the application of the YOLOv8-seg architecture to the instance segmentation of pets (cats and dogs), using the public Oxford-IIIT Pet dataset. Since the original dataset only provides dense masks (trimaps), a conversion pipeline was developed to produce the polygon format required by the architecture. The model was trained via transfer learning from COCO-pretrained weights and evaluated using mask mean Average Precision (mAP) metrics. Results show [to be filled in after training], demonstrating the feasibility of using detection architectures with a segmentation head for fine-grained problems under limited computational resources.

1. Introdução

A visão computacional compreende um conjunto de tarefas voltadas à extração de informação semântica a partir de imagens digitais, das quais três são consideradas fundamentais: classificação, detecção de objetos e segmentação. Enquanto a classificação indica *o que* está presente em uma imagem e a detecção localiza objetos por meio de caixas delimitadoras, a segmentação é a tarefa mais granular, atribuindo uma classe a **cada pixel** da imagem [Ronneberger et al. 2015]. Dentro da segmentação, distingue-se ainda a segmentação semântica, que rotula pixels por classe sem diferenciar objetos individuais, da segmentação de instância, que além de classificar também separa cada ocorrência de um objeto com sua própria máscara.

Aplicações de segmentação são numerosas: em imagens médicas, permite delimitar órgãos e lesões; em veículos autônomos, permite distinguir via, calçada e pedestres;

em edição de imagem, permite o recorte automático de objetos do fundo. Este trabalho tem como objetivo aplicar uma arquitetura de segmentação de instância a um problema de domínio simples e bem documentado – a segmentação de animais de estimação em fotografias – de modo a explorar, na prática, todo o pipeline de um projeto de *deep learning*: preparação de dados, treinamento por *transfer learning*, avaliação quantitativa e análise qualitativa dos resultados.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica sobre segmentação e a arquitetura utilizada; a Seção 3 descreve o dataset, o pipeline de preparação dos dados e os detalhes de treinamento; a Seção 4 apresenta e discute os resultados obtidos; e a Seção 5 conclui o trabalho e aponta direções futuras.

2. Fundamentação Teórica

2.1. Segmentação semântica e de instância

Redes convolucionais do tipo *encoder-decoder*, como a U-Net [Ronneberger et al. 2015], consolidaram-se como abordagem clássica para segmentação semântica: um caminho de contração (*encoder*) extrai características em múltiplas escalas, enquanto um caminho de expansão (*decoder*) reconstrói a resolução espacial original, auxiliado por conexões de salto (*skip connections*) que preservam detalhes finos. Essa abordagem, no entanto, não distingue instâncias individuais de uma mesma classe quando há múltiplos objetos sobrepostos ou próximos na imagem.

2.2. A família YOLO e o YOLOv8-seg

A família YOLO (*You Only Look Once*) [Redmon et al. 2016] popularizou a detecção de objetos em estágio único (*single-stage*), predizendo simultaneamente, em uma única passagem pela rede, as caixas delimitadoras, as classes e as confianças de todos os objetos de uma imagem – em contraste com abordagens de dois estágios, mais precisas porém mais lentas. Versões mais recentes da arquitetura, mantidas pela Ultralytics [Jocher et al. 2023], estendem esse princípio à segmentação de instância (*YOLOv8-seg*): além da caixa e da classe, a rede prediz coeficientes que combinam protótipos de máscara compartilhados, gerando uma máscara de pixels específica para cada instância detectada, mantendo a eficiência computacional característica da família.

3. Metodologia

3.1. Dataset

Foi utilizado o *Oxford-IIIT Pet Dataset* [Parkhi et al. 2012], composto por 7.349 imagens de 37 raças de cães e gatos, cada uma acompanhada de uma máscara de segmentação em formato *trimap*, na qual cada pixel é rotulado como pertencente ao animal (pet), ao fundo, ou à borda de contorno entre ambos. O dataset é distribuído publicamente e possui divisão oficial entre um conjunto de treino/validação e um conjunto de teste.

3.2. Conversão de máscaras para polígonos

Como o YOLOv8-seg espera anotações no formato de polígono normalizado (e não máscaras densas), foi implementado um pipeline de conversão: para cada imagem, os

pixels rotulados como pet ou borda no trimap foram unidos em uma máscara binária de primeiro plano; em seguida, o contorno externo dessa máscara foi extraído com o algoritmo de Suzuki e Abe [Suzuki and Abe 1985], implementado na biblioteca OpenCV (`cv2.findContours`), e normalizado pelas dimensões da imagem para gerar o rótulo no formato exigido pela arquitetura, com uma única classe (*pet*). O conjunto de treino/validação original foi então subdividido em treino (85%) e validação (15%), mantendo o conjunto de teste oficial intacto para a avaliação final.

3.3. Arquitetura e treinamento

Foi utilizado o modelo *YOLOv8n-seg*, a variante mais leve da família, com pesos pré-treinados no conjunto de dados COCO [Lin et al. 2014], adaptados ao problema por *transfer learning*. O treinamento foi conduzido com $[X]$ épocas, tamanho de *batch* de 16 imagens e resolução de entrada de 640×640 pixels, utilizando os hiperparâmetros padrão da biblioteca *ultralytics* (otimizador SGD/Adam com *learning rate* adaptativo e função de perda combinada de caixa, classe e máscara). O treinamento foi executado em ambiente Google Colab, com GPU gratuita (NVIDIA T4).

3.4. Métricas de avaliação

O desempenho do modelo foi avaliado no conjunto de teste por meio de métricas padrão de detecção/segmentação: *mean Average Precision* com limiar de sobreposição de máscara de 0,5 (mAP50) e a média entre os limiares de 0,5 a 0,95 (mAP50-95), além de precisão e *recall*.

4. Resultados e Discussão

A Tabela 1 apresenta as métricas obtidas no conjunto de teste após o treinamento do modelo.

Tabela 1. Resultados no conjunto de teste

Métrica	Valor
mAP50 (máscara)	[preencher]
mAP50-95 (máscara)	[preencher]
Precisão	[preencher]
Recall	[preencher]

[Discussão a preencher: comparar os resultados quantitativos com o esperado, comentar qualitativamente os acertos e erros observados nas Figuras ??, e discutir as principais dificuldades do desenvolvimento (dados, hardware, hiperparâmetros).]

Uma limitação observada é que o Oxford-IIIT Pet contém, em sua grande maioria, uma única instância de animal por imagem, o que reduz a vantagem prática da segmentação de instância sobre uma abordagem puramente semântica – ponto relevante para trabalhos futuros que explorem datasets com múltiplos animais por cena.

5. Conclusão

Este trabalho apresentou a aplicação da arquitetura YOLOv8-seg à tarefa de segmentação de instância de animais de estimação, cobrindo todo o pipeline de um projeto de *deep*

learning: desde a conversão de anotações do formato original do dataset para o formato exigido pela arquitetura, passando pelo treinamento por *transfer learning*, até a avaliação quantitativa e qualitativa dos resultados. [Concluir com uma síntese dos principais achados após a análise dos resultados.]

Como trabalhos futuros, sugere-se: (i) a comparação com arquiteturas de segmentação semântica pura, como a U-Net, sob as mesmas condições experimentais; (ii) a avaliação em datasets com múltiplas instâncias por imagem, de modo a explorar melhor a capacidade de segmentação de instância do YOLOv8-seg; e (iii) a análise do custo-benefício entre variantes do modelo (*nano*, *small*, *medium*) em termos de acurácia *versus* tempo de inferência.

Referências

- Jocher, G., Chaurasia, A., and Qiu, J. (2023). Ultralytics yolov8. <https://github.com/ultralytics/ultralytics>. Acessado em julho de 2026.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *European Conference on Computer Vision (ECCV)*, pages 740–755.
- Parkhi, O. M., Vedaldi, A., Zisserman, A., and Jawahar, C. V. (2012). Cats and dogs. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3498–3505.
- Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788.
- Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.
- Suzuki, S. and Abe, K. (1985). Topological structural analysis of digitized binary images by border following. *Computer Vision, Graphics, and Image Processing*, 30(1):32–46.